

Manchas Criminais em Alagoas: Uma Análise Espaço-Temporal dos Crimes Violentos Letais Intencionais para Apoio à Tomada de Decisão em Segurança Pública

Antonio Guilherme da Silva¹, Antonio Rodrigo L. A. Tenório¹, Sandro Gomes Paulino¹

¹Instituto de Computação – Universidade Federal de Alagoas (UFAL)
Maceió – AL – Brasil

ags2@ic.ufal.br, arlat@ic.ufal.br, sgp@ic.ufal.br

Abstract. *The state of Alagoas historically presents one of the highest rates of intentional lethal violent crimes (CVLI) in Brazil. This paper presents a spatio-temporal analysis of a public CVLI microdata set covering 2012–2026 (21,217 raw records; 20,369 after cleaning). Through exploratory analysis, temporal heatmaps, and geographic visualisation, we identified that 60.36% of crimes occur during nighttime and early morning (18h–5h), 37.88% on weekends, and Maceió accounts for 33.33% of all state occurrences. As an operational component, an XGBoost Poisson regressor was trained on a full scenario grid, normalised by demographic population estimates from the 2022 IBGE Census, to score relative risk by profile. A comparison of supervised classifiers (Logistic Regression, Random Forest and XGBoost) was also carried out; the XGBoost classifier reached 92.42% accuracy and $94.70\% \pm 0.71\%$ in 5-fold cross-validation, but these figures are optimistic and not reliable, because the risk label is derived from whole-sample aggregates and causes target leakage (Section 6). Results support a data-driven predictive patrolling protocol for dynamic resource allocation, subject to the caveats discussed.*

Resumo. *Alagoas historicamente apresenta um dos maiores índices de Crimes Violentos Letais Intencionais (CVLI) do Brasil. Este trabalho apresenta uma análise espaço-temporal de uma base pública de microdados de CVLI (2012–2026): 21.217 registros brutos e 20.369 após a limpeza. Por meio de análise exploratória, mapas de calor e visualização geográfica, identificou-se que 60,36% dos crimes ocorrem no período noturno e de madrugada (18h–5h), 37,88% nos fins de semana, e Maceió responde por 33,33% das ocorrências. Como componente operacional, treinou-se um XGBoost Poisson Regressor sobre uma matriz completa de cenários, normalizado por estimativas populacionais do Censo IBGE 2022, para pontuar o risco relativo por perfil. Também foi realizada uma comparação de classificadores supervisionados (Regressão Logística, Random Forest e XGBoost); o classificador XGBoost atingiu 92,42% de acurácia e $94,70\% \pm 0,71\%$ em validação cruzada de 5 folds, mas esses valores são otimistas e não confiáveis, pois o rótulo de risco é derivado de agregados de toda a base, gerando vazamento de alvo (Seção 6). Os resultados embasam um protocolo de patrulhamento preditivo orientado a dados, sujeito às ressalvas discutidas.*

1. Introdução

O Brasil é um dos países com maior número absoluto de homicídios no mundo, e o estado de Alagoas historicamente figura entre as unidades federativas com maiores taxas de mortalidade violenta por habitante [Cerqueira et al. 2021]. Os Crimes Violentos Letais Intencionais (CVLI) — categoria que engloba homicídios dolosos, latrocínios e lesões corporais seguidas de morte — representam não apenas uma tragédia humana de proporções alarmantes, mas também um grave problema socioeconômico, com impactos diretos sobre o desenvolvimento regional, o capital social e a qualidade de vida da população [Cerqueira and Soares 2014].

Apesar da gravidade do problema, os recursos de segurança pública são frequentemente alocados de maneira uniforme e reativa, sem considerar os padrões espaço-temporais da criminalidade. Abordagens tradicionais de policiamento tendem a responder ao crime após sua ocorrência, em vez de antecipá-lo por meio da análise de dados históricos [Sherman et al. 1989]. Com o advento da Ciência de Dados e da Aprendizagem de Máquina, tornou-se tecnicamente viável transformar grandes volumes de registros históricos de criminalidade em inteligência operacional capaz de orientar decisões de policiamento preventivo [Buczak and Guven 2016].

O presente trabalho aborda a seguinte questão de pesquisa: *Existem padrões de sazonalidade — por dia da semana, mês do ano ou faixa de horário — associados a surtos de violência em microrregiões específicas de Alagoas que precedem aumentos nos índices de CVLI?* Para respondê-la, foi realizada uma análise espaço-temporal sobre a base pública de microdados de CVLI disponibilizada pela Secretaria de Estado da Segurança Pública de Alagoas (SSP-AL), cobrindo 14 anos de registros (2012–2026).

As principais contribuições deste trabalho são: (i) identificação de padrões temporais e geográficos de concentração do CVLI em Alagoas; (ii) construção e avaliação de um modelo preditivo de risco relativo baseado em XGBoost Poisson, normalizado por população exposta; e (iii) proposição de recomendações acionáveis para gestores de segurança pública fundamentadas nos dados analisados.

O restante deste artigo está organizado da seguinte forma: a Seção 2 descreve a base de dados e o pré-processamento; a Seção 3 apresenta a análise exploratória; a Seção 4 detalha os métodos aplicados; a Seção 5 apresenta as métricas e a estratégia de avaliação; a Seção 6 discute os resultados; e a Seção 7 conclui o trabalho.

2. Base de Dados

2.1. Origem e Descrição

A base de dados utilizada é a *CVLI AL – Base de Microdados*, disponibilizada publicamente pelo Portal de Dados Abertos do Estado de Alagoas, mantido pela Secretaria de Estado da Segurança Pública (SSP-AL) [SSP-AL 2024]. O conjunto de dados abrange o período de janeiro de 2012 a abril de 2026, totalizando **21.217 registros** e **14 colunas**, entre as quais: identificador do registro (`ID_CONTROLE`), tipo de crime (`SUBJETIVIDADE`), data e hora do fato, município, bairro, sexo, cor/raça, idade e escolaridade da vítima, local do fato e instrumento utilizado. A versão utilizada neste trabalho cobre registros até 30 de abril de 2026. Como o recurso é atualizado periodicamente no portal, recomenda-se citar sempre a data de acesso e a versão obtida, evitando divergências com revisões posteriores do conjunto.

2.2. Pré-processamento

A base apresentou importantes desafios de qualidade, refletindo a realidade de registros administrativos de segurança pública no Brasil. As principais etapas de pré-processamento realizadas foram as seguintes.

Tratamento de valores ausentes: As variáveis `ESCOLARIDADE` (74,15% de valores faltantes) e `OCUPAÇÃO` (67,59%) foram descartadas por inviabilidade de imputação. A variável `COR/RAÇA` (5,12% de ausência) foi imputada pela moda — a categoria “Parda” —, enquanto `IDADE` (2,11%), `INSTRUMENTO` (1,87%) e `LOCAL DO FATO` (0,43%) foram tratados por exclusão dos registros faltantes. Ressalte-se que a imputação de cor/raça pela moda reforça a categoria majoritária e, portanto, infla estatísticas descritivas baseadas nessa variável; tais números devem ser lidos com essa ressalva (Seção 6).

Engenharia de atributos temporais: A partir da coluna de data, foram criadas as variáveis: `ano`, `mes`, `dia_semana` e `periodo_dia`, segmentado em quatro faixas: Madrugada (0h–5h), Manhã (6h–11h), Tarde (12h–17h) e Noite (18h–23h).

Discretização de idade: A idade contínua foi transformada na variável categórica `faixa_etaria` com os grupos: 0–11, 12–17, 18–24, 25–29, 30–39, 40–59 e 60+.

Agrupamento de variáveis categóricas: O instrumento utilizado foi consolidado em quatro categorias (`grupo_instrumento`): Arma de fogo, Arma branca, Espancamento e Outros. O local do fato foi consolidado em `grupo_local`: Espaço público, Entorno de casa, Ambiente interno e Área externa/isolada.

Normalização de nomes: Nomes de municípios e bairros foram normalizados (remoção de acentos, padronização de maiúsculas/minúsculas) para viabilizar a junção com dados geográficos de centroide do IBGE.

Após o pré-processamento, a base resultante continha **20.369 registros** (dos 21.217 originais) com todas as variáveis essenciais preenchidas, utilizados de forma consistente em todas as análises descritivas e na modelagem subsequentes.

3. Estatística Descritiva e Análise Exploratória

3.1. Evolução Temporal

A análise da evolução anual do CVLI em Alagoas revela uma tendência de queda ao longo da série histórica, com pico em 2013 (2.181 registros) e mínimo em 2021 (1.028 registros, desconsiderando-se 2026, ainda parcial), conforme a Figura 1. Este comportamento pode ser parcialmente associado a políticas públicas de segurança implementadas no período, como o fortalecimento de programas estaduais de combate à violência [Ratton et al. 2014].

3.2. Padrões Temporais

A distribuição por período do dia revela forte concentração noturna: o período Noite (18h–23h) concentra 42,89% das ocorrências, seguido por Tarde (22,72%), Madrugada (17,47%) e Manhã (16,92%). Combinando-se os períodos Noite e Madrugada, **60,36% dos CVLI ocorrem entre 18h e 5h**. A análise por dia da semana indica que **37,88% das ocorrências concentram-se nos finais de semana** (sábado e domingo).




Figura 1. Evolução mensal do CVLI em Alagoas (2012–2026), evidenciando sazonalidade intra-anual e tendência de queda ao longo da série histórica.

O mapa de calor da Figura 2 cruza o período do dia com o dia da semana, revelando padrões claros e repetíveis: a concentração nas noites de sexta-feira, sábado e domingo é consistente ao longo de toda a série histórica, sugerindo uma sazonalidade semanal estrutural do fenômeno.




Figura 2. Mapa de calor: distribuição dos CVLI por dia da semana e período do dia (2012–2026). Cores mais intensas indicam maior concentração de ocorrências.

3.3. Distribuição Geográfica

A distribuição geográfica dos CVLI em Alagoas é marcadamente concentrada. O município de Maceió, capital do estado, responde sozinho por **33,33% (6.789 registros)** de todas as ocorrências. As cinco cidades com maior incidência — Maceió, Arapiraca (7,24%), Rio Largo (4,15%), União dos Palmares (2,24%) e Marechal Deodoro (2,16%) — concentram **49,12%** dos CVLI do estado, ou seja, praticamente metade das ocorrências. A Figura 3 apresenta a distribuição geográfica acumulada por município por meio de um mapa de bolhas posicionado nos centroides municipais (não há geometria de polígonos, de modo que não se trata de um mapa coroplético propriamente dito).




Figura 3. Evolução espaço-temporal dos CVLI por janelas temporais em Alagoas (2012–2026). Cada painel representa um intervalo agregado de anos, permitindo comparar a persistência e a redistribuição das manchas criminais ao longo do tempo. O tamanho dos marcadores indica o volume de ocorrências por município em cada janela, evidenciando a concentração recorrente dos casos em polos urbanos específicos, especialmente na região de Maceió e em municípios de maior incidência no estado.

3.4. Perfil das Vítimas

A análise do perfil demográfico das vítimas confirma padrões amplamente documentados na literatura sobre violência letal no Brasil [Cerqueira et al. 2021]: **93,44% das vítimas são do sexo masculino; 59,19% têm entre 15 e 29 anos; e 87,89% são pardas ou pretas** (na base limpa, em que a cor/raça ausente foi imputada como “Parda”; considerando apenas os registros com cor/raça informada, a proporção é 87,47%). A interseção desses três fatores — homens jovens pardos ou pretos — representa 50,59% de todas as vítimas, evidenciando uma vulnerabilidade estrutural acentuada nesse grupo.

Quanto ao instrumento utilizado, **79,07% dos CVLI foram cometidos com arma de fogo** (Projétil de Arma de Fogo – PAF). Entre homens de 15 a 29 anos, essa proporção sobe para 85,27%. Em contraste, arma branca ou espancamento são relativamente mais frequentes entre vítimas do sexo feminino (36,05%) e em ambientes internos (27,24%), sugerindo um perfil de violência doméstica nesses casos.

4. Métodos Avaliados

A análise foi conduzida em duas frentes complementares: (i) análise exploratória espaço-temporal para identificação de padrões e manchas criminais; e (ii) modelagem preditiva baseada em taxa de risco relativo por perfil demográfico-contextual.

4.1. Análise Espaço-Temporal

A construção dos mapas de calor temporais utilizou tabelas dinâmicas (*pivot tables*) cruzando as variáveis `dia_semana` e `periodo_dia`, agregando a contagem de ocorrências. Para a análise geográfica, foram calculados centroides municipais a partir de dados do IBGE, permitindo a construção de mapas de bolhas por centroide — e não mapas coropléticos, dada a ausência de geometria de polígonos — e mapas de calor interativos com a biblioteca *Folium* [Folium Development Team 2023].

4.2. Modelagem Preditiva de Risco

A modelagem preditiva foi restrita ao município de Maceió por duas razões objetivas: (i) o município concentra 33,33% de todos os registros de CVLI da base, fornecendo volume suficiente para treinamento; e (ii) dispõe de dados populacionais por bairro no Censo IBGE 2022, o que permite calcular uma **taxa de risco relativo por perfil demográfico**, mais justa do que a simples contagem absoluta de ocorrências.

Construção da matriz de cenários: O modelo não foi treinado sobre registros individuais, mas sobre uma matriz completa de cenários possíveis, formada pela combinação de:

$$\text{bairro} \times \text{sexo} \times \text{faixa etária} \times \text{dia da semana} \times \text{turno} \times \text{tipo de local}$$

Para cada cenário foi contabilizado o número histórico de CVLI. Os cenários sem ocorrência foram mantidos com valor zero, permitindo que o modelo aprendesse também perfis de baixo risco.

Normalização por população exposta: Para evitar que bairros mais populosos ou grupos majoritários dominassem a análise por volume bruto, foi estimada a população de cada perfil a partir do Censo IBGE 2022:

$$\text{pop_perfil} = \text{pop_bairro} \times \text{prop_sexo} \times \text{prop_faixa_etária} \quad (1)$$

A variável-alvo do modelo foi a **taxa anualizada de CVLI por 100 mil habitantes**:

$$\text{taxa_risco} = \frac{\text{crimes_anuais}}{\text{pop_perfil}} \times 100.000 \quad (2)$$

em que `crimes_anuais` é a contagem histórica do cenário dividida pelo número de anos da série. Na implementação atual utilizou-se o número de anos-calendário distintos (15) como divisor; como o período efetivamente coberto corresponde a aproximadamente 14,3 anos (jan/2012–abr/2026, com 2026 ainda parcial), esse divisor subestima levemente a taxa anualizada — para Maceió, por exemplo, a taxa real passa de 47,34 para cerca de 49,58/100 mil — e deve ser ajustado ao intervalo efetivo em versões futuras.

Essa taxa foi classificada em três níveis operacionais — *baixo*, *médio* e *alto* — com base em uma média de referência recalibrada sobre os cenários com crimes reais, separada por sexo, para evitar distorções causadas pelo grande número de combinações zeradas no grid. Cabe registrar que essa média de referência é estimada sobre toda a base, o que vincula a definição das classes ao conjunto completo (ver a discussão sobre vazamento de alvo na Seção 6).

Algoritmo e codificação: O algoritmo escolhido foi o **XGBoost Regressor com objetivo Poisson** [Chen and Guestrin 2016], adequado para eventos raros baseados em contagens, pois penaliza corretamente a cauda da distribuição sem inflar previsões em cenários de zero ocorrências. As variáveis categóricas (bairro, sexo, faixa etária, dia da semana, turno e local do fato) foram codificadas via `OneHotEncoder` antes do treinamento, resultando em 6 atributos base expandidos por *one-hot encoding*.

Explicabilidade com SHAP: Para suporte à interpretação operacional, o modelo incorpora valores SHAP (*SHapley Additive exPlanations*) [Hastie et al. 2009], que quantificam a contribuição individual de cada atributo na previsão de risco. Isso permite que gestores de segurança compreendam, em linguagem natural, por que determinado perfil, bairro ou horário recebeu alta classificação de risco.

É importante distinguir dois artefatos. O modelo **operacional**, efetivamente carregado pelo *dashboard*, é o XGBoost Poisson Regressor descrito acima, ajustado sobre todo o *grid* de cenários sem conjunto de teste apartado e sem validação cruzada. Separadamente, e apenas para fins de comparação e linha de base, foi conduzido um **experimento de classificação** sobre os registros individuais de Maceió (6.789 ocorrências), em que cada ocorrência recebe um rótulo de risco (*baixo*, *médio* ou *alto*) derivado do percentil de frequência de seu contexto dentro do grupo demográfico. Nesse experimento avaliaram-se **Regressão Logística** [Hastie et al. 2009], **Random Forest** [Breiman 2001] e **XGBoost** (classificador), com divisão treino/teste 80/20 estratificada pela variável-alvo. Como o rótulo é construído a partir de contagens da base inteira e essas mesmas contagens determinam as variáveis de entrada, esse experimento sofre de **vazamento de alvo** — suas métricas, reportadas na Seção 6, são otimistas e não devem ser interpretadas como medida de generalização (ver Seção 6).

5. Métricas e Estratégia de Avaliação

5.1. Métricas

A avaliação dos modelos utilizou as seguintes métricas: **Acurácia** (proporção de classificações corretas no total); **F1-Score macro** (média aritmética do F1-Score por classe, adequada para avaliar desempenho equilibrado entre todas as classes); e **Precisão** e **Revocação** por classe, para análise detalhada do comportamento do modelo em cada categoria de risco. A Matriz de Confusão foi utilizada para inspeção dos erros de classificação.

5.2. Estratégia de Avaliação

Além da divisão treino/teste (80/20), foi realizada **validação cruzada estratificada com 5 folds** para estimar a variância do desempenho e garantir que os resultados não fossem sensíveis à partição específica dos dados [Hastie et al. 2009]. Esta estratégia é recomendada para conjuntos de dados de tamanho moderado, pois oferece estimativas mais robus-

tas da capacidade de generalização do modelo. A estratificação por classe garantiu que a distribuição das categorias de risco fosse mantida em cada *fold*. Cabe a ressalva, no entanto, de que a validação cruzada acima se aplica ao **experimento de classificação** e *não* corrige o vazamento de alvo: como o rótulo de risco é definido a partir de agregados de toda a base, a separação em *folds* não isola informação entre treino e teste, de modo que as estimativas permanecem otimistas (Seção 6). O modelo Poisson operacional, por sua vez, não foi submetido a partição de teste nem a validação cruzada no *pipeline* de treino.

6. Resultados e Discussão

6.1. Desempenho dos Modelos (Experimento de Classificação)

A Tabela 1 apresenta os resultados do experimento de classificação descrito na Seção 4.2 — treinado sobre os registros individuais de Maceió, distinto do modelo Poisson operacional — no conjunto de teste (20% dos dados). **Estes resultados devem ser lidos com forte ressalva**, pois o rótulo de risco sofre vazamento de alvo, conforme detalhado adiante.

Tabela 1. Comparação de desempenho no experimento de classificação sobre registros individuais de Maceió (conjunto de teste). Atenção: métricas otimistas devido a vazamento de alvo (ver Seção 6); não correspondem ao modelo Poisson operacional.

Modelo	Acurácia	F1-Score Macro
Regressão Logística	84,02%	83,98%
Random Forest	89,40%	89,19%
XGBoost	92,42%	92,35%

Nesse experimento, o XGBoost obteve os maiores valores em ambas as métricas, superando a Regressão Logística em 8,4 pontos percentuais e o Random Forest em 3,0 pontos percentuais de acurácia, com $94,70\% \pm 0,71\%$ na validação cruzada de 5 *folds*.

Ressalva metodológica (vazamento de alvo). As métricas acima *superestimam* a capacidade real de generalização e não devem ser interpretadas como evidência de um preditor de alta acurácia. O rótulo `classe_risco` é construído a partir de contagens de frequência calculadas sobre *toda* a base, antes da divisão treino/teste, e essas mesmas contagens são determinadas pelas variáveis usadas como entrada do modelo. Em consequência, o alvo é praticamente uma função determinística das *features*: ao reproduzir a partição, verificou-se que **80,78% das linhas de teste compartilham com o treino a mesma combinação que define o rótulo**, de modo que o modelo essencialmente recupera um valor já presente nos dados de treino. A validação cruzada *não* mitiga esse problema, pois o vazamento ocorre na própria definição do alvo. Em uma verificação fora da amostra do modelo Poisson operacional (divisão 80/20 sobre combinações de cenário não vistas), o poder preditivo é fraco ($R^2 \approx 0,10$), o que reforça que esse componente deve ser usado como ferramenta de pontuação/triagem de risco relativo, e não como classificador de alta acurácia.

A Figura 4 apresenta a comparação visual entre os modelos, e a Tabela 2 detalha as métricas por classe para o modelo XGBoost.




Figura 4. Comparação de desempenho entre os modelos avaliados: Regressão Logística, Random Forest e XGBoost.

Tabela 2. Métricas por classe — XGBoost no experimento de classificação. Valores afetados pelo vazamento de alvo discutido na Seção 6.

Classe	Precisão	Revocação	F1-Score
Alta	94%	96%	95%
Baixa	93%	94%	94%
Média	90%	87%	88%

A maior taxa de confusão ocorreu entre as classes *média* e as demais, o que é esperado dado o caráter limítrofe dos casos de risco intermediário. A classe *alta* obteve o melhor desempenho (F1 = 95%), o que é particularmente relevante do ponto de vista operacional, pois erros de classificação na direção de subestimar o risco alto têm maior custo social.

6.2. Insight Acionável

Os resultados da análise espaço-temporal convergem para uma recomendação central: *60,36% dos CVLI em Alagoas ocorrem no período noturno e de madrugada (18h–5h), concentrados em manchas criminais identificáveis em Maceió e em outras quatro cidades que, juntas, respondem por praticamente metade (49,12%) de todos os CVLI do estado. Esse padrão sugere que o patrulhamento uniforme aloca parte expressiva dos recursos em zonas e períodos de baixo risco — a magnitude exata desse desperdício, porém, não foi quantificada neste estudo e permanece como hipótese a ser testada. Diante disso, recomendamos avaliar um protocolo de patrulhamento preditivo dinâmico, alocando viaturas por faixa de horário e microrregião conforme as concentrações identificadas. A recomendação apoia-se sobretudo na concentração espaço-temporal evidenciada pela análise descritiva e pelo mapa de calor (60,36% dos CVLI no período noturno e nas cinco principais microrregiões); ela não se apoia nas métricas do experimento de classificação, que são otimistas por vazamento de alvo (Seção 6). Após seis meses, o efeito da ação poderia ser avaliado pela redução do CVLI nas áreas de intervenção, acompanhando-se a taxa de incidentes nas zonas adjacentes como controle do efeito de deslocamento. A título de meta operacional — e não de previsão derivada do modelo —, a literatura de hot spots*

policing sugere quedas da ordem de 10% a 20% em áreas de intervenção concentrada, parâmetro que poderia balizar a avaliação.

Esta recomendação é consistente com a literatura de *hot spots policing*, que demonstra reduções médias de 10–20% na criminalidade em áreas de intervenção concentrada [Sherman et al. 1989, Weisburd 2016].

6.3. Limitações

Algumas limitações devem ser consideradas na interpretação dos resultados. Primeiro, e de forma mais crítica, o **experimento de classificação** (Tabela 1) sofre de vazamento de alvo: o rótulo de risco é derivado de contagens calculadas sobre toda a base e essas mesmas contagens determinam as *features*, de modo que 80,78% das linhas de teste reaparecem, na prática, no treino. Suas métricas são, portanto, otimistas e não medem generalização. O modelo Poisson operacional, por sua vez, foi ajustado sobre todo o *grid* sem conjunto de teste apartado; uma verificação posterior fora da amostra indicou poder preditivo fraco ($R^2 \approx 0,10$), o que o caracteriza como ferramenta de triagem de risco relativo, não como preditor de alta acurácia.

Segundo, a base apresenta altas taxas de valores ausentes nas variáveis de escolaridade e ocupação, limitando análises socioeconômicas mais aprofundadas; além disso, a cor/raça foi imputada pela moda (“Parda”), o que infla estatísticas descritivas baseadas nessa variável e deve ser considerado ao ler a proporção de 87,89% de vítimas pardas ou pretas. Terceiro, o modelo preditivo foi treinado exclusivamente com dados de Maceió, podendo não generalizar para municípios menores com dinâmicas distintas. Quarto, a ausência de coordenadas geográficas precisas para cada ocorrência limitou a análise ao nível de município e bairro; as visualizações “geográficas” são mapas de bolhas posicionados em centroides (no caso dos bairros, coordenadas aproximadas geradas por deslocamento determinístico em torno do centro da cidade), e não mapas coropléticos nem produto de clusterização espacial. Quinto, as concentrações temporais e geográficas são apresentadas de forma descritiva: não foram aplicados testes de significância estatística nem análise causal, de modo que afirmações sobre o efeito de intervenções permanecem hipóteses. Sexto, a taxa anualizada utiliza como divisor o número de anos-calendário (15) em vez do intervalo efetivo (cerca de 14,3 anos), subestimando levemente as taxas. Por fim, o modelo não incorpora COR/RAÇA como atributo de normalização da taxa de risco, pois dados populacionais por raça/cor na granularidade de bairro não estão disponíveis no Censo IBGE 2022.

7. Conclusão

Este trabalho mostrou que os Crimes Violentos Letais Intencionais em Alagoas apresentam padrões espaço-temporais claros e consistentes. A concentração de 60,36% das ocorrências no período noturno e de madrugada, de 37,88% nos finais de semana e de 33,33% no município de Maceió evidencia que o fenômeno da violência letal não é aleatório — é estruturado e recorrente ao longo da série histórica.

A partir desses padrões, construiu-se um modelo XGBoost Poisson, treinado sobre uma matriz de cenários normalizada por estimativas populacionais do Censo IBGE 2022, como ferramenta operacional de pontuação de risco relativo por perfil. Cabe registrar que a verificação fora da amostra indica poder preditivo ainda limitado ($R^2 \approx 0,10$) e que

as métricas elevadas do experimento de classificação (92,42% de acurácia; 94,70% em validação cruzada) refletem vazamento de alvo, não devendo ser tomadas como medida de acurácia do instrumento. Ainda assim, o trabalho demonstra ser viável organizar dados públicos já disponíveis em um instrumento de apoio à decisão, sem custo adicional de coleta, desde que aprimorados o desenho do alvo e a validação do modelo. A título de referência, a literatura de *hot spots policing* associa intervenções concentradas a reduções da ordem de 10% a 20% nas áreas-alvo, parâmetro que pode orientar a avaliação de um eventual protocolo de patrulhamento preditivo.

Como trabalhos futuros, destacam-se: (i) expansão do modelo para os 102 municípios de Alagoas; (ii) integração com dados socioeconômicos do IBGE e com variáveis de raça/cor para análise de fatores estruturais; (iii) implantação de um *dashboard* interativo para uso operacional pela SSP-AL com explicações em linguagem natural via SHAP; e (iv) aplicação de modelos de séries temporais para previsão de tendências de médio prazo.

A base de dados utilizada é pública e está disponível em: dados.al.gov.br/catalogo/dataset/cvli-2012-a-2023-base-microdados.

Referências

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Buczak, A. L. and Guven, E. (2016). A survey of data mining and machine learning methods for cyber security. *IEEE Communications Surveys & Tutorials*, 18(2):1153–1176.
- Cerqueira, D. et al. (2021). *Atlas da Violência 2021*. IPEA / Fórum Brasileiro de Segurança Pública, Brasília.
- Cerqueira, D. and Soares, R. R. (2014). The socioeconomic impact of crime in Latin America. *IZA Discussion Paper*, (8456).
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proc. 22nd ACM SIGKDD*, pages 785–794.
- Folium Development Team (2023). Folium: Python data, leaflet.js maps.
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning*. Springer, New York, 2nd edition.
- Ratton, J. L., Cid, C., and Misse, C. (2014). *O Pacto pela Vida e a Redução de Homicídios em Pernambuco*. Edições Bagaço, Recife.
- Sherman, L. W., Gartin, P. R., and Buerger, M. E. (1989). Hot spots of predatory crime. *Criminology*, 27(1):27–56.
- SSP-AL (2024). CVLI AL – base de microdados. Portal de Dados Abertos de Alagoas.
- Weisburd, D. (2016). Does hot spots policing inevitably lead to displacement? *Criminology & Public Policy*, 15(3):853–861.